

Universidad Nacional de Colombia

Análisis Numérico

Prof. Carlos Manuel Orrego Franco

Neural ODEs sobre Datos Reales

COVID-19 JHU — Nuevos casos diarios (178 países $\times$ 400 días)

Integrante 1: Valentina Aristizábal Sierra

Integrante 2: Camilo Andrés Jaime Rojas

Entrega: 27 de mayo de 2026

Contents

1	Descripción del dataset	2
2	Hiperparámetros elegidos y justificación	2
3	Tabla de resultados (RMSE)	3
4	Figuras	4
4.1	Comparación de modelos (60% de observaciones)	5
4.2	Curvas de aprendizaje	6
5	Respuestas a las preguntas de análisis	6
5.1	P1 — ¿Con qué porcentaje de observaciones empieza a ganar la Neural ODE o el Latent ODE?	6
5.2	P2 — ¿Por qué el encoder RNN corre en orden inverso al tiempo?	6
5.3	P3 — ¿Hubo algún resultado sorpresivo?	7
5.4	P4 — ¿En qué tipo de problema NO recomendaríamos una Neural ODE?	7
6	Conclusiones	8
	Referencias	8

1. Descripción del dataset

El dataset utilizado proviene del repositorio COVID-19 del Center for Systems Science and Engineering (CSSE) de la Universidad Johns Hopkins (JHU), que consolidó diariamente casos confirmados a nivel mundial desde enero de 2020. Para este experimento se procesó la serie de nuevos casos diarios para 178 países, abarcando 400 días consecutivos. La variable es unidimensional ($\dim = 1$), correspondiente a nuevos casos normalizados mediante transformación logarítmica suavizada, con rango efectivo $[-1.098, 7.928]$. El conjunto se dividió en 143 trayectorias de entrenamiento y 35 de prueba.

Desde el punto de vista dinámico, las series de COVID-19 exhiben el comportamiento oscilatorio y no lineal que motiva el uso de EDOs para su modelamiento. Al igual que el modelo SIR estudiado en los notebooks NB03–NB04 del curso ($dI/dt = \beta SI - \gamma I$), la dinámica de contagio presenta crecimiento exponencial inicial, un pico y una caída. Sin embargo, a diferencia del SIR clásico, las trayectorias reales muestran múltiples oleadas, efectos de política pública (confinamientos, vacunación) y heterogeneidades profundas entre países — factores no observables en la serie de casos, como se aprecia en la Figura 1.

Esta variabilidad representa el principal desafío del dataset: países con dinámicas muy distintas (olas rápidas y agudas versus comportamientos prolongados multi-pico) coexisten en el mismo conjunto. El muestreo es formalmente regular (400 pasos igualmente espaciados), pero el ruido inherente a los reportes epidemiológicos (subregistro, cambios en criterios diagnósticos, retardo en notificación) introduce una irregularidad implícita que pone a prueba la capacidad de los modelos de aprender señal sobre ruido.




Figure 1: Exploración del dataset: 8 trayectorias de países representativos (nuevos casos diarios normalizados). Se observa la diversidad de patrones — olas únicas pronunciadas, picos múltiples y señales planas — que refleja la heterogeneidad epidemiológica global.

2. Hiperparámetros elegidos y justificación

Se ejecutaron dos configuraciones para explorar el efecto del tamaño del modelo. La **Configuración A** ($\dim_{\text{latente}} = 8$) apuesta por mayor capacidad representacional: el vector z_0 puede codificar simultáneamente información sobre la fase de la ola, la tasa de crecimiento y la heterogeneidad entre países. La **Configuración B** ($\dim_{\text{latente}} = 4$)

opera con la premisa de que un espacio latente más pequeño funciona como regularizador implícito, forzando al modelo a aprender solo las componentes más explicativas de la dinámica — relevante dado el alto nivel de ruido del dataset.

Table 1: Hiperparámetros de ambas configuraciones y justificación.

Hiperparámetro	Config A	Config B	Justificación
<code>dim_latente</code>	8	4	Dimensión de z_0 . Config A captura más modos de variabilidad; Config B regulariza para datos ruidosos.
<code>n_pasos_ode</code>	10	6	Pasos RK4. Más pasos $\Rightarrow$ mayor precisión numérica pero mayor costo $\mathcal{O}(n)$.
<code>learning_rate</code>	0.001	0.001	Tasa Adam estándar para Neural ODEs [1]. Tasas mayores producen inestabilidades en el solver RK4.
<code>n_epochs</code>	35	35	La función de costo se estabilizó $\approx$ época 30 en ambas configs (ver Figura 3).
<code>batch_size</code>	32	32	Balance entre varianza del gradiente y memoria de GPU. Estándar en la literatura.
<code>dim_oculto_f</code>	48	32	Capacidad de f_θ . Proporcional a <code>dim_latente</code> para mantener expresividad.
<code>dim_oculto_enc</code>	32	24	Unidades del encoder RNN inverso. Coherente con z_0 .
<code>dim_oculto_dec</code>	48	32	Capacidad del decoder; $\geq$ <code>dim_oculto_f</code> para reconstrucción fiel.

3. Tabla de resultados (RMSE)

Las tablas siguientes reportan el RMSE de reconstrucción (*rec*) y extrapolación (*ext*) para cada modelo y fracción de observaciones, replicando el esquema experimental de la Tabla 2 de rubanova2019. El valor “—” en extrapolación al 100% es esperado: con todos los puntos observados no quedan puntos futuros para evaluar.

Table 2: Configuración A: `dim_latente`= 8, `n_pasos_ode`= 10, `dim_oculto_f`= 48.

Modelo	30% obs		60% obs		100% obs	Paráms
	rec	ext	rec	ext	rec	
Método Clásico (splines)	0.000	0.114	0.000	0.087	0.000	4
Neural ODE	0.500	0.501	0.498	0.505	0.501	3 721
Latent ODE	0.576	0.576	0.573	0.579	0.576	7 593

Table 3: Configuración B: $\text{dim_latente}=4$, $\text{n_pasos_ode}=6$, $\text{dim_oculto_f}=32$.

Modelo	30% obs		60% obs		100% obs	Paráms
	rec	ext	rec	ext	rec	
Método Clásico (splines)	0.000	0.114	0.000	0.087	0.000	4
Neural ODE	0.503	0.504	0.501	0.508	0.504	1 581
Latent ODE	0.561	0.561	0.559	0.565	0.561	3 717

El Método Clásico (splines) logra RMSE de reconstrucción exactamente 0.000 en todos los casos — los splines interpolantes pasan exactamente por los puntos observados. Sin embargo, su RMSE de extrapolación es considerablemente más alto (≈ 0.114 con 30% de observaciones). La Neural ODE mantiene un comportamiento consistente entre reconstrucción y extrapolación (~ 0.50), lo que indica que no memoriza sino que aprende una dinámica general. El Latent ODE presenta valores ligeramente superiores a la Neural ODE en ambas configuraciones.

4. Figuras

4.1. Comparación de modelos (60% de observaciones)




Figure 2: Comparación de los tres modelos con 60% de observaciones en 3 trayectorias de prueba. Los puntos son las observaciones disponibles, la línea discontinua es la predicción y la línea sólida gris es la trayectoria real. Fila superior: Método Clásico (splines). Fila media: Neural ODE. Fila inferior: Latent ODE.

4.2. Curvas de aprendizaje




Figure 3: Curvas de aprendizaje para Neural ODE (verde) y Latent ODE (azul) durante 35 épocas. La Neural ODE converge de forma más suave ($\text{loss}_0 \approx 0.35$); el Latent ODE muestra una caída inicial pronunciada desde $\text{loss}_0 \approx 0.55$ seguida de estabilización $\approx$ época 30.

5. Respuestas a las preguntas de análisis

5.1. P1 — ¿Con qué porcentaje de observaciones empieza a ganar la Neural ODE o el Latent ODE?

Con base en los resultados obtenidos (Tablas 2 y 3), la Neural ODE **no supera al Método Clásico en extrapolación** en ninguna de las fracciones evaluadas (30%, 60%, 100%) para este dataset. Con 30% de observaciones, el Método Clásico registra RMSE de extrapolación de 0.114 frente a ~ 0.501 – 0.504 de la Neural ODE. Con 60%, el clásico mejora a 0.087 mientras la Neural ODE se mantiene alrededor de 0.505– 0.508 .

Este resultado es coherente con lo trabajado en los NB06–07. Los splines cúbicos son interpoladores exactos y, para series epidémicas con continuidad local, su extrapolación a corto plazo puede ser precisa. La Neural ODE aprende una dinámica *promedio* sobre 143 países de entrenamiento y, al predecir en los 35 países de prueba, esa dinámica generalizada puede no coincidir con el régimen local de cada país. En otras palabras, el modelo clásico tiene la ventaja de ajustarse específicamente a cada trayectoria, mientras la Neural ODE generaliza desde el entrenamiento; en datasets con dinámica muy heterogénea entre trayectorias (como COVID-19 global), esa generalización penaliza el rendimiento individual. La ventaja de la Neural ODE se manifestaría con más épocas, mayor capacidad, o en datasets donde la dinámica compartida entre trayectorias es más fuerte (como el SIR sintético de la Opción A).

5.2. P2 — ¿Por qué el encoder RNN corre en orden inverso al tiempo?

Esta es una de las decisiones de diseño más elegantes del Latent ODE [2]. El encoder RNN procesa la secuencia $\{x_T, x_{T-1}, \dots, x_1\}$ de atrás hacia adelante para poder computar el estado inicial z_0 en el tiempo t_0 como el estado final del procesamiento. La lógica es

directa: el Latent ODE modela la trayectoria como la solución de una EDO integrada desde z_0 hacia adelante en el tiempo. Para inferir z_0 , el encoder necesita condensar toda la información observada en un vector de condición inicial, y t_0 es el punto más antiguo de la secuencia.

Si el encoder corriese en orden cronológico normal, su estado oculto al finalizar correspondería al tiempo más reciente (t_T), no al más antiguo — lo que haría incoherente la integración hacia adelante desde t_0 . Además, por el fenómeno de *olvido selectivo* del RNN (estudiado en NB05), el estado final estaría dominado por las observaciones más recientes, perdiendo información sobre las condiciones iniciales de la dinámica. En COVID-19, esto significaría que z_0 reflejaría el estado actual de la ola pero olvidaría la pendiente inicial de crecimiento — precisamente la información necesaria para integrar la EDO desde el inicio.

5.3. P3 — ¿Hubo algún resultado sorpresivo?

El resultado más llamativo es que el **Latent ODE no supera a la Neural ODE** sino que obtiene RMSE consistentemente más alto en todas las condiciones (~ 0.576 vs. ~ 0.501 en Config A; ~ 0.561 vs. ~ 0.503 en Config B). Intuitivamente se esperaría lo contrario: el Latent ODE es un modelo más sofisticado con encoder RNN y espacio latente probabilístico, diseñado para capturar la heterogeneidad entre trayectorias y producir predicciones personalizadas.

Hay varias razones que explican este resultado:

1. La curva de aprendizaje (Figura 3) muestra que el Latent ODE parte de una pérdida inicial considerablemente más alta (~ 0.55 vs. ~ 0.35), lo que con solo 35 épocas resulta en convergencia más lenta e incompleta.
2. El dataset COVID-19 tiene una única dimensión y muestreo regular, lo que reduce la ventaja del encoder RNN inverso: al no haber irregularidad temporal real, la información que el encoder debe condensar es más simple y la Neural ODE puede aproximarla adecuadamente.
3. El ruido epidemiológico dificulta que el encoder aprenda un z_0 representativo, degradando toda la integración subsecuente.

Este resultado es consistente con rubanova2019: la ventaja del Latent ODE se manifiesta principalmente con muestreo genuinamente irregular y variables multidimensionales, como en PhysioNet.

5.4. P4 — ¿En qué tipo de problema NO recomendaríamos una Neural ODE?

Con base en los resultados de este experimento, identificamos tres escenarios en los que una Neural ODE no es la herramienta adecuada:

1. **Cuando los datos son ruidosos y la interpolación exacta es suficiente.** El Método Clásico obtuvo RMSE de reconstrucción exactamente 0 en todos los casos frente al ~ 0.50 de la Neural ODE, siendo prácticamente instantáneo (0.0 s vs. 2473 s). Si el objetivo es rellenar valores faltantes en una serie donde los puntos observados son confiables, los splines son superiores sin ningún costo computacional.
2. **Cuando el presupuesto computacional es limitado.** Con 143 trayectorias de entrenamiento, la Neural ODE requirió ~ 41 minutos y el Latent ODE ~ 54 minutos

en Colab. En un contexto de epidemiología operativa donde se necesitan actualizaciones diarias, este costo es inviable. El número de parámetros (3 721–7 593) relativamente alto respecto al tamaño del dataset también puede inducir sobreajuste sin regularización explícita.

3. **Cuando la dinámica entre trayectorias es extremadamente heterogénea sin un campo vectorial f_θ común.** En COVID-19 global, las diferencias entre países responden a factores externos no observables en la serie de casos. Una Neural ODE que aprende una f_θ compartida promedia estas diferencias. En este caso, métodos que ajustan parámetros por trayectoria (como el SIR con `scipy.optimize`) pueden ser más precisos porque se especializan en cada contexto individual.

6. Conclusiones

Esta actividad permitió materializar el recorrido completo desde la teoría de EDOs hasta la aplicación de Neural ODEs y Latent ODEs sobre datos epidemiológicos reales. Los resultados muestran que, en el dataset COVID-19 con muestreo regular y una sola dimensión, el método clásico con splines sigue siendo competitivo en extrapolación a corto plazo, mientras que la Neural ODE logra una dinámica más robusta y consistente entre reconstrucción y extrapolación, sin memorizar.

El Latent ODE, a pesar de su mayor sofisticación, no superó a la Neural ODE aquí — probablemente por convergencia más lenta con pocas épocas y por la ausencia de irregularidad temporal real, que es precisamente el escenario en que brilla según rubanova2019.

La comparación de dos configuraciones confirmó que reducir el espacio latente (Config B) ofrece un compromiso razonable: resultados casi equivalentes con la mitad de parámetros y menor tiempo de entrenamiento. En síntesis, las Neural ODEs son herramientas poderosas cuando la dinámica es genuinamente compartida entre trayectorias y el muestreo es irregular — condiciones que posicionan al Latent ODE como el enfoque de referencia para series fisiológicas multivariadas como las del dataset PhysioNet, el escenario canónico del paper de rubanova2019.

Referencias

References

- [1] Chen, R. T. Q., Rubanova, Y., Bettencourt, J., & Duvenaud, D. (2018). Neural Ordinary Differential Equations. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.
- [2] Rubanova, Y., Chen, R. T. Q., & Duvenaud, D. (2019). Latent ODEs for Irregularly-Sampled Time Series. *Advances in Neural Information Processing Systems (NeurIPS)*, 32.
- [3] Dong, E., Du, H., & Gardner, L. (2020). An interactive web-based dashboard to track COVID-19 in real time. *The Lancet Infectious Diseases*, 20(5), 533–534.